esprit
Se former autrement
HONORIS UNITED UNIVERSITIES



Arbres de décision

UP: GL/BD
Réalisé par : Equipe ML Appliqué

United Nations Educational, Scientific and Cultural Organization · UNESCO Chair "Project-based learning" · ESPRIT School of engineering, Tunisia
EUR-ACE® Délivrée par la Commission des Titres d'Ingénieur
CONFÉRENCE DES GRANDES ÉCOLES
cdio

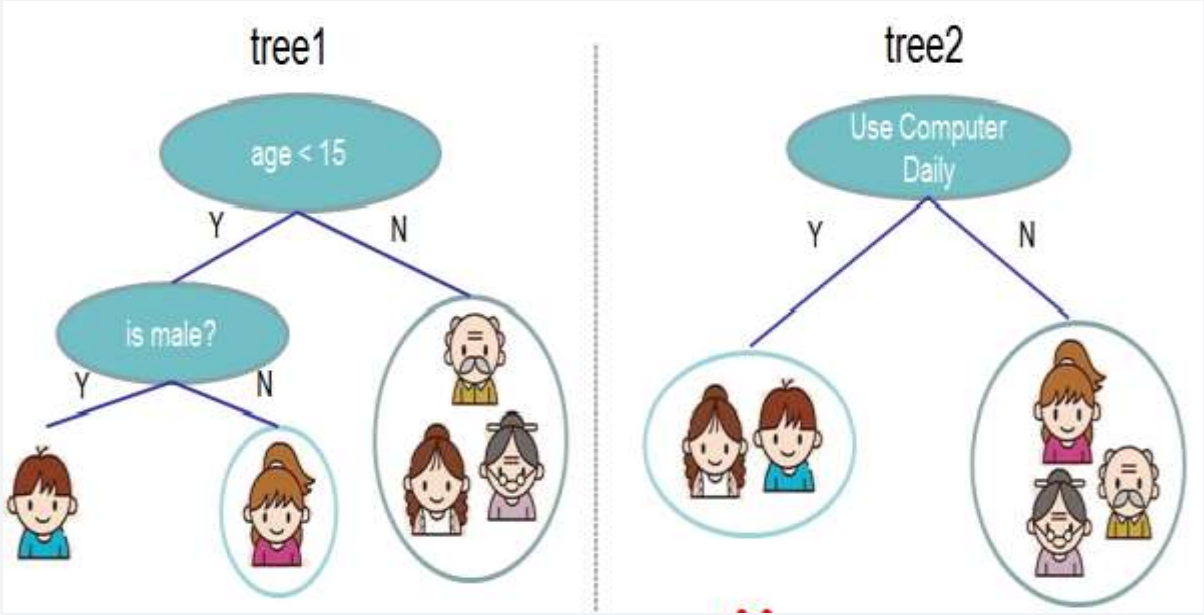
Plan

- Introduction
- Concepts de base
- Algorithme
- Choix de la racine
- Algorithme CART
- Exemple de construction de l’arbre
- Avantages et inconvénients

Introduction

- ✓ Un arbre de décision est **un modèle prédictif** qui utilise une **structure arborescente** pour prendre **des décisions** basées sur **des règles**.

- ✓ C'est une technique de classification **hiérarchique descendante**



Exemple

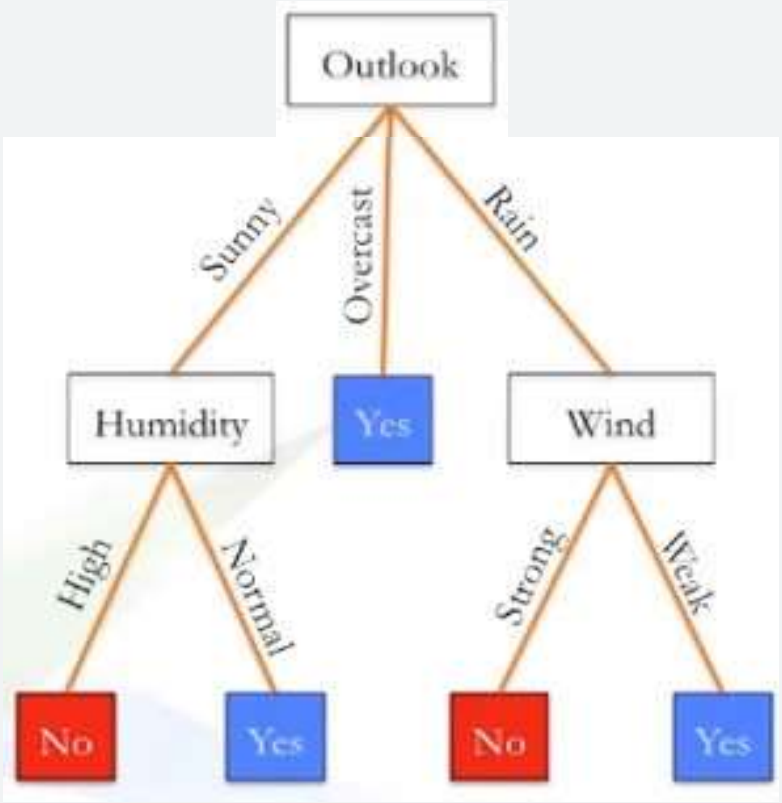


Day	Outlook	Temp	Humidity	Wind	Play Tennis
1	Sunny	Hot	High	Weak	No
2	Sunny	Hot	High	Strong	No
3	Overcast	Hot	High	Weak	Yes
4	Rain	Mild	High	Weak	Yes
5	Rain	Cool	Normal	Weak	Yes
6	Rain	Cool	Normal	Strong	No
7	Overcast	Cool	Normal	Weak	Yes
8	Sunny	Mild	High	Weak	No
9	Sunny	Cool	Normal	Weak	Yes
10	Rain	Mild	Normal	Strong	Yes
11	Sunny	Mild	Normal	Strong	Yes
12	Overcast	Mild	High	Strong	Yes
13	Overcast	Hot	Normal	Weak	Yes
14	Rain	Mild	High	Strong	No

Exemple

Day	Outlook	Temp	Humidity	Wind	Play Tennis
1	Sunny	Hot	High	Weak	No
2	Sunny	Hot	High	Strong	No
3	Overcast	Hot	High	Weak	Yes
4	Rain	Mild	High	Weak	Yes
5	Rain	Cool	Normal	Weak	Yes
6	Rain	Cool	Normal	Strong	No
7	Overcast	Cool	Normal	Weak	Yes
8	Sunny	Mild	High	Weak	No
9	Sunny	Cool	Normal	Weak	Yes
10	Rain	Mild	Normal	Strong	Yes
11	Sunny	Mild	Normal	Strong	Yes
12	Overcast	Mild	High	Strong	Yes
13	Overcast	Hot	Normal	Weak	Yes
14	Rain	Mild	High	Strong	No

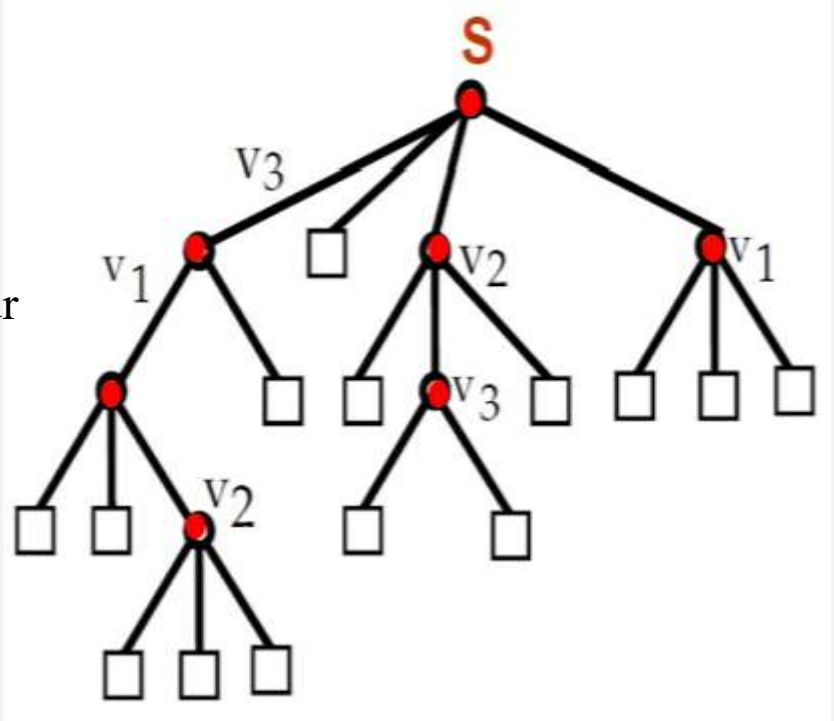
Arbre de décision



Concepts de base

nœud:

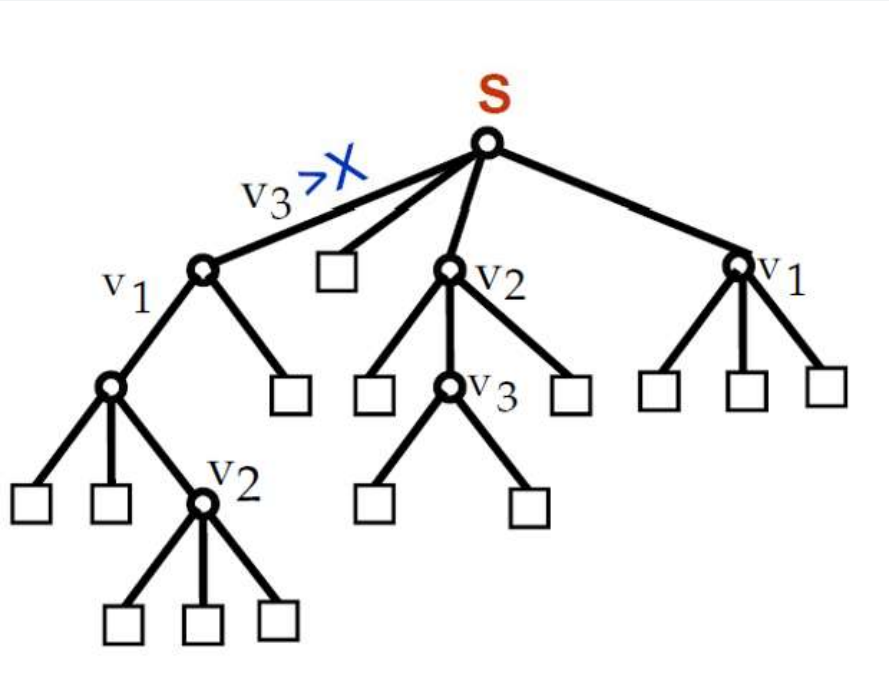
- ✓ **Nœud racine:** Premier nœud, point de départ de l'arbre.
- ✓ **Nœud interne** : Un nœud qui représente un test sur un attribut.



Concepts de base

Une branche:

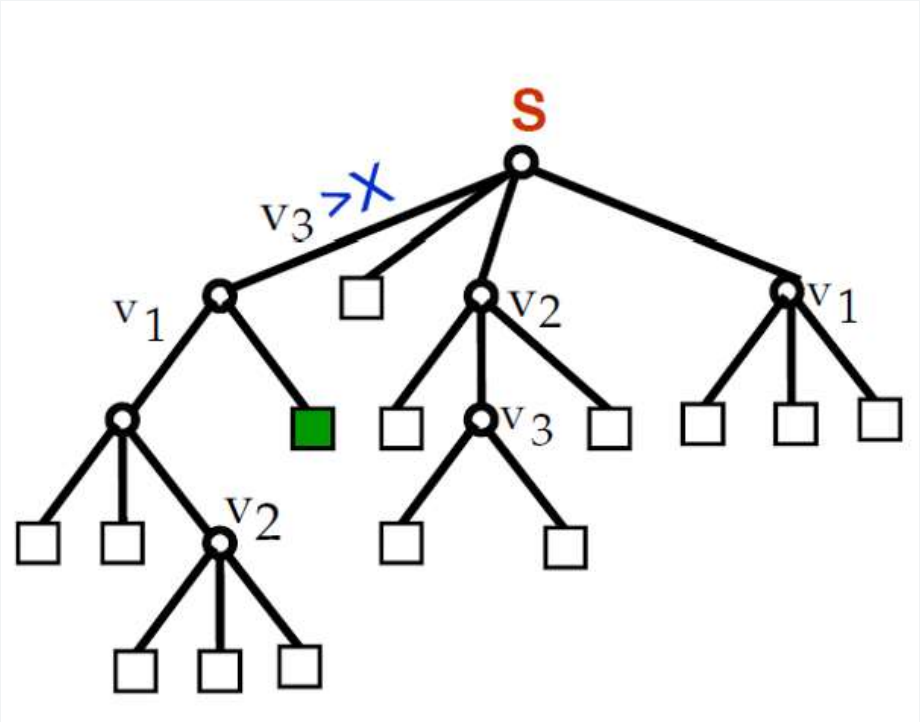
Chaque branche représente un choix qui résulte du test sur un attribut.



Concepts de base

Une feuille:

Noeuds terminaux qui donnent la décision finale (classe prédite).

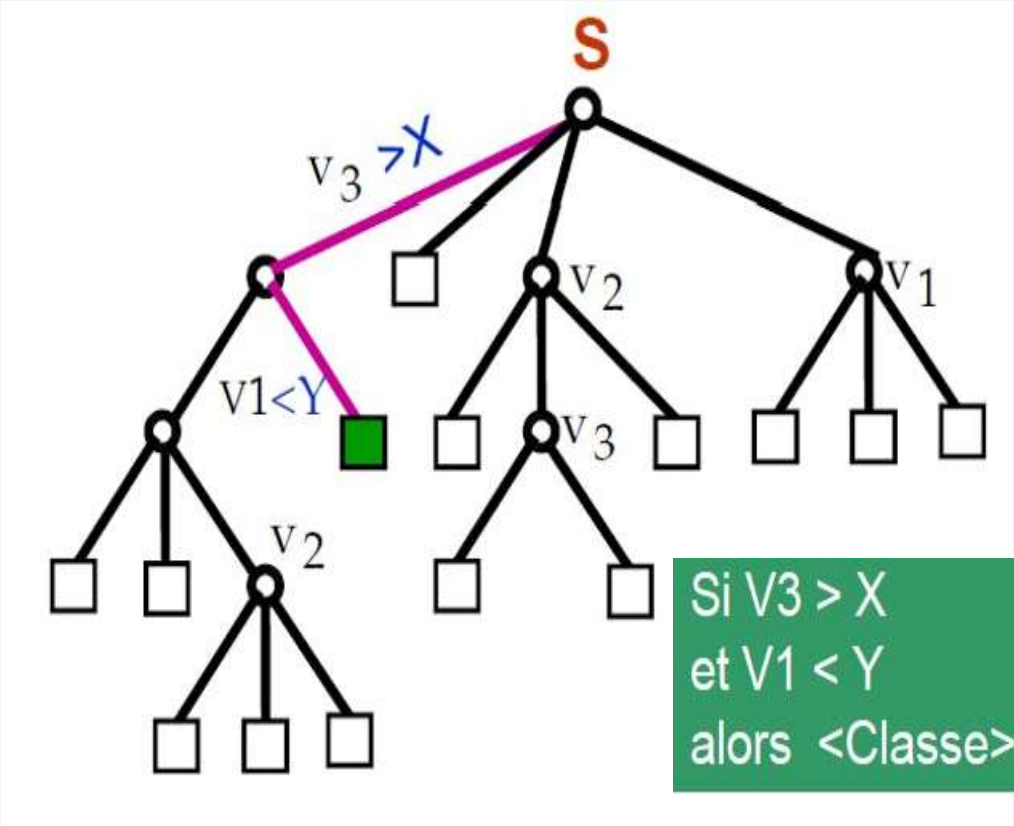


Concepts de base

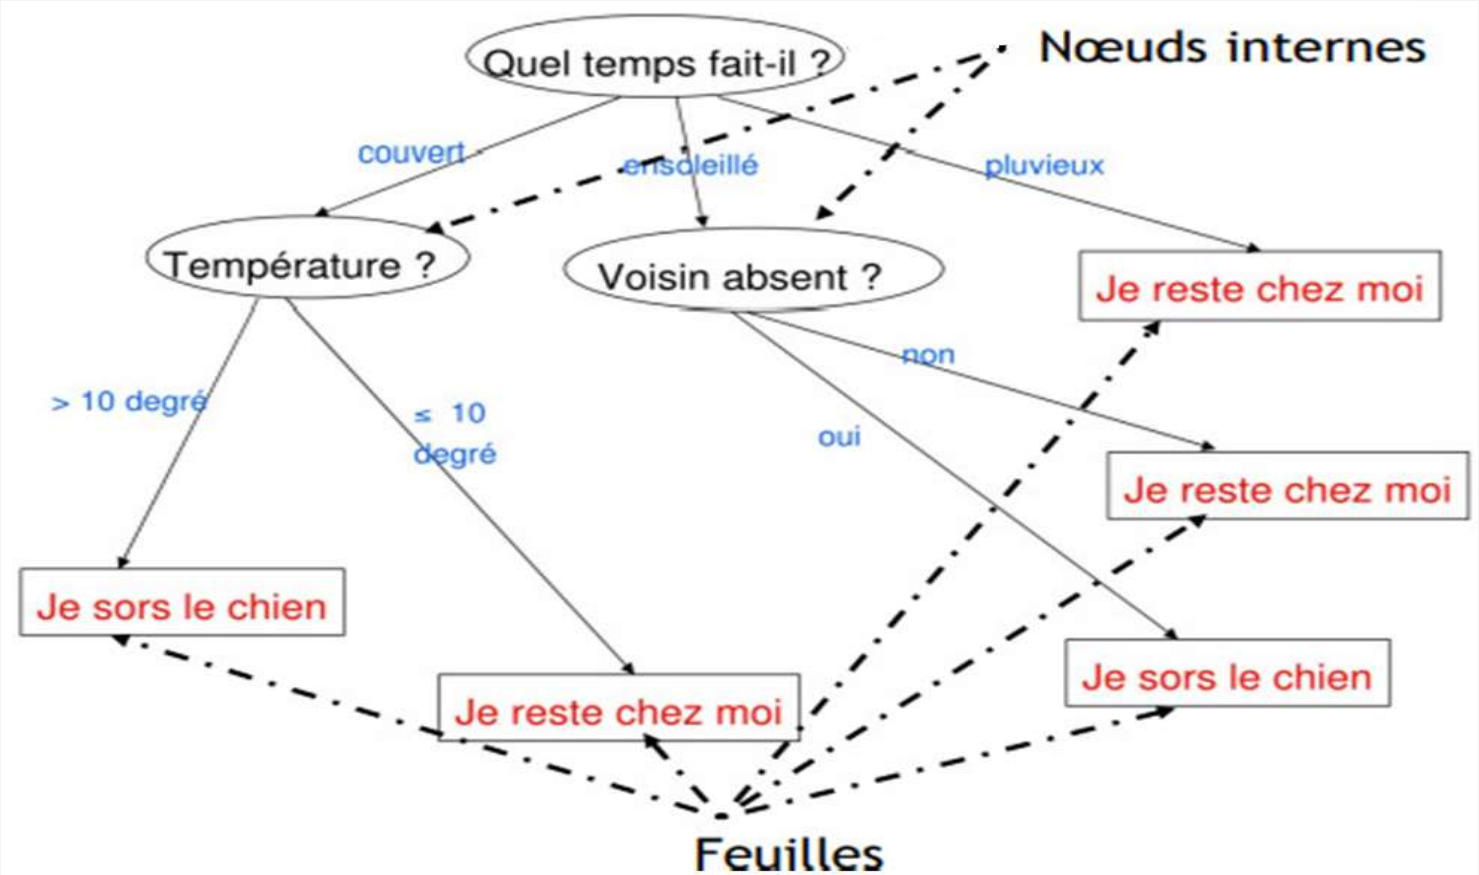
Un parcours:

Pour classer un nouvel enregistrement:

- ✓ Partir de la racine
- ✓ Répondre aux questions en suivant la branche correspondante
- ✓ Lire la valeur de la feuille atteinte



Exemple


Quel temps fait-il ?
Nœuds internes
couvert
ensoleillé
pluvieux
Température ?
Voisin absent ?
Je reste chez moi
non
> 10 degré
≤ 10 degré
oui
Je reste chez moi
Je sors le chien
Je sors le chien
Je reste chez moi
Feuilles

Problématique

- Choix du nœud racine: Quelle variable a choisir ?
- Quelle variable choisit-on à chaque nœud?
- Quelle branche définit-on sous chaque nœud?



Principe de base

- Pour chaque nœud, on choisit la variable qui sépare le mieux les individus en fonction des catégories de la variable cible.
- On répète l'opération jusqu'à ce qu'elle ne soit plus possible ou plus souhaitable
- Les feuilles ainsi construites sont toutes majoritairement constitués d'individus d'une seule classe.
- La branche allant de la racine à une feuille constitue une règle de classification.
- L'ensemble des règles constitue le modèle

Algorithme de base

Début

L’algorithme part de la racine de l’arbre.

Boucle de parcours de l’arbre

Pour chaque nœud, on choisit la variable qui sépare le mieux les individus en fonction des catégories de la variable cible.

Séparation des individus.

Fin de boucle
Fin

Conditions d'arrêt du partitionnement :

- Tous les enregistrements d'un nœud se trouvent dans la même classe.
- Il n'y a plus d'attributs pour faire le partitionnement, dans ce cas, le nœud est transformé en feuille et la classe associée est la plus fréquente dans l'ensemble.
- Il n'y a plus d'enregistrements.

Choix du nœud racine

On place à la racine l'attribut le plus pur:

- Celui où tous les exemples sont de la même classe
- Celui qui sépare le mieux les exemples positifs et négatifs
- C'est l'attribut le plus discriminant

Mesure d'impureté :

- ✓ Entropie de Shannon
- ✓ Entropie de Boltzmann
- ✓ Index de Gini

Algorithmes d’apprentissage

CART	[Briemen, 1984]
ID3	[Quinlan, 1986]
SIPINA	[Zighed, 1992]
C4.5	[Quinlan, 1993]
..	

Algorithmes d’apprentissage

CART	[Briemen, 1984]
ID3	[Quinlan, 1986]
SIPINA	[Zighed, 1992]
C4.5	[Quinlan, 1993]
..	

Algorithme CART

Il utilise l'indice de Gini qu'on cherche à minimiser:

$$IG = 1 - \sum_{i=1}^{n} f_i^2$$

- f_i fréquence de la classe c_i dans le nœud
- N : nombre de classes à prédire

⟹ **Plus l'indice de Gini est bas, plus le nœud est pur**

Exemple de construction de l'arbre

ENSOLEILLE
OUI: 2/5
NON 3/5
on recalcule pas
puisque déjà utilisé

Pluvieux
Oui: 3/5
NON 2/5

Jour	Ciel	Température	Humidité	Vent	Jouer au Tennis
1	Ensoleillé	Chaud	Elevée	Faible	Non
2	Ensoleillé	Chaud	Elevée	Fort	Non
[redacted]					
4	Pluvieux	Moyen	Normale	Faible	Oui
5	Pluvieux	Frais	Normale	Faible	Oui
6	Pluvieux	Frais	Normale	Fort	Non
[redacted]					
8	Ensoleillé	Moyen	Elevée	Faible	Non
9	Ensoleillé	Frais	Normale	Faible	Oui
10	Pluvieux	Moyen	Normale	Faible	Oui
11	Ensoleillé	Moyen	Normale	Fort	Oui
[redacted]					
14	Pluvieux	Moyen	Elevée	Fort	Non

Exemple de construction de l'arbre

Ciel	Oui	Non	Nbr D'instance
Ensoleillé	2	3	5
Nuageux	4	0	4
Pluvieux	3	2	5

- Gini(Ciel=Ensoleillé) = $1 - (2/5)^2 - (3/5)^2 = 0.48$
- Gini(Ciel =Nuageux) = $1 - (4/4)^2 - (0/4)^2 = 0$
- Gini(Ciel =Pluvieux) = $1 - (3/5)^2 - (2/5)^2 = 0.48$

Ensuite, nous allons calculer la somme pondérée des indices de Gini pour la caractéristique **« Ciel ».**

Gini(Ciel) = (5/14) x 0.48 + (4/14) x 0 + (5/14) x 0.48 = 0.342

Exemple de construction de l'arbre

Température	Oui	Non	Nbr D'instance
Chaud	2	2	4
Moyen	3	1	4
Frais	4	2	6

- Gini(Temp=Chaud) = 1 - (2/4) ²- (2/4) ² = 0.5
- Gini(Temp=Moyen) = 1 - (3/4) ²- (1/4) ² = 0.375
- Gini(Temp=Frais) = 1 - (4/6) ² - (2/6) ² = 0.445

Ensuite, nous allons calculer la somme pondérée des indices de Gini pour la caractéristique **« Température ».**

Gini(Temp) = (4/14) × 0.5 + (4/14) x 0.375 + (6/14) × 0.445 = 0.439

Exemple de construction de l'arbre

Humidité	Oui	Non	Nbr D'instance
Elevée	3	4	7
Normale	6	1	7

- Gini(Humidité=Elevée) = 1 - (3/7) ² - (4/7) ² =0.489
- Gini(Humidité=Normale) = 1 - (6/7) ² - (1/7) ² = 0.244

La somme pondérée pour la caractéristique "humidité" sera calculée ensuite.

Gini(Humidité) = (7/14) x 0.489 + (7/14) × 0.244 = 0.367

Exemple de construction de l'arbre

Vent	Oui	Non	Nbr D'instance
Faible	6	2	8
Fort	3	3	6

- Gini(Vent=Faible) = 1 - (6/8) ² - (2/8) ² = 0.375
- Gini(Vent=Fort) = 1 - (3/6) ² - (3/6) ² = 0.5

Gini(Vent) = (8/14) x 0.375 + (6/14) x 0.5= 0.428

Exemple de construction de l’arbre

Choix de la racine:

Variable	Indice de gini
Ciel	0.342
Température	0.439
Humidité	0.367
Vent	0.428

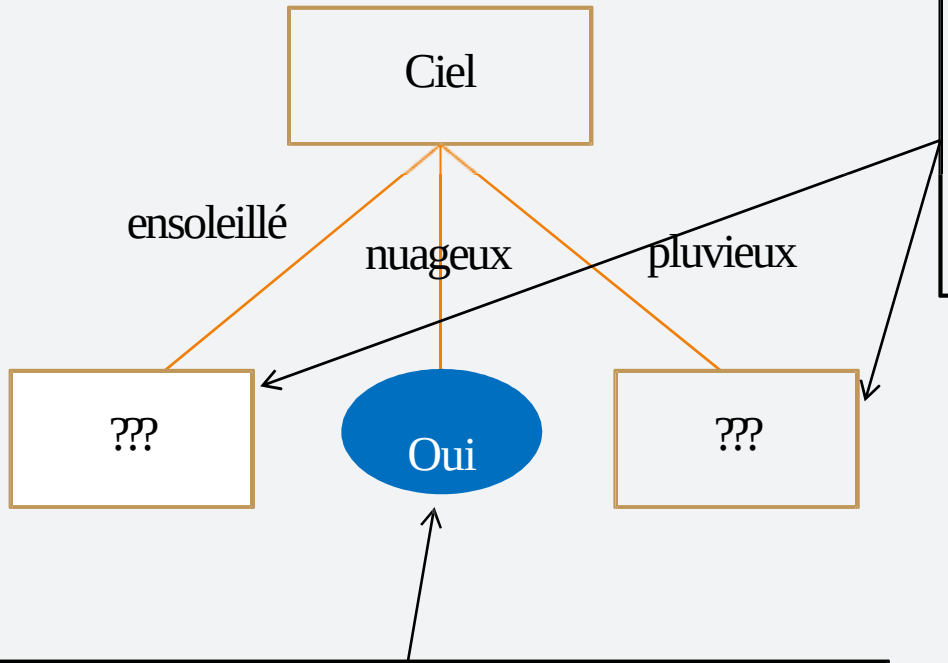
Exemple de construction de l’arbre

Choix de la racine:

Variable	Indice de gini
Ciel	0.342
Température	0.439
Humidité	0.367
Vent	0.428

Exemple de construction de l'arbre

On obtient l'arbre partiel suivant:

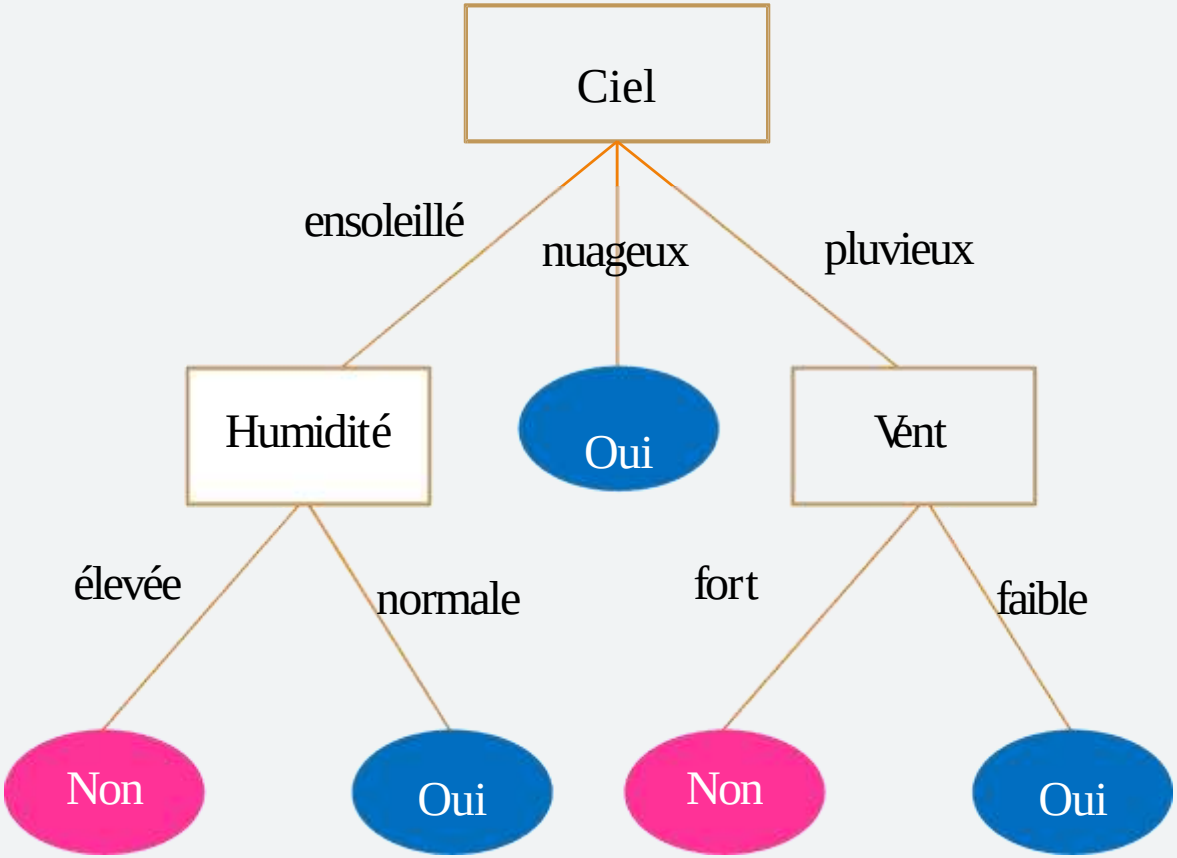


encore des exemples positifs et négatifs, alors il faut recommencer le même calcul du gain d'information, mais avec les sous-ensembles restant

Lorsque le ciel est nuageux, il reste uniquement des exemples positifs, donc ce nœud devient une feuille avec une valeur de Oui pour la fonction visée.

Exemple de construction de l'arbre

En effectuant les calculs restant, on obtient:



Avantages et inconvénients

Avantages :

- Simple à comprendre et à interpréter.
- Non paramétrique : ne fait pas d’hypothèses sur la distribution des données.
- Fonctionne avec des données qualitatives et quantitatives.

Inconvénients :

- Peut devenir trop complexe, menant à du surapprentissage.
- Sensible aux petites variations dans les données.