esprit
Se former autrement
HONORIS UNITED UNIVERSITIES



Support Vector Machine

Réalisé par:
Equipe ML Appliqué

United Nations Educational, Scientific and Cultural Organization
UNESCO Chair "Project-based learning" ESPRIT School of engineering, Tunisia
EUR-ACE® Délivrée par la Commission des Titres d'Ingénieur
CONFERENCE DES GRANDES ÉCOLES
cdio CONCEIVE DESIGN IMPLEMENT OPERATE

Support Vector Machine

ID	Clump	UnifSize	UnifShape	MargAdh	SingEpiSize	BareNuc	BlandChrom	NormNucl	Mit	Class
1000025	5	1	1	1	2	1	3	1	1	benign
1002945	5	4	4	5	7	10	3	2	1	benign
1015425	3	1	1	1	2	2	3	1	1	malignant
1016277	6	8	8	1	3	4	3	7	1	benign
1017023	4	1	1	3	2	1	3	1	1	benign
1017122	8	10	10	8	7	10		7	1	malignant
1018099	1	1	1	1	2	10	3	1	1	benign
1018561	2	1	2	H	2	1	3	1	1	benign
1033078	2	1	1	1	2	1	1	1	5	benign
1033078	4	2	1	1	2	1	2	1	1	benign

Modeling

ID	Clump	UnifSize	UnifShape	MargAdh	SingEpiSize	BareNuc	BlandChrom	NormNucl	Mit	Class
1000015	6	1	1	1	7	1	3	1	1	Benign

Prediction



Accuracy = 89%

This is a classification algorithm that classifies cases by finding a separator.

Idée de SVM

SVM fonctionne comme suit:

1- En mappant d'abord les données vers un espace d'entité dimensionnel élevé afin que les points de données puissent être catégorisés, même lorsque les données ne sont pas autrement séparables linéairement.

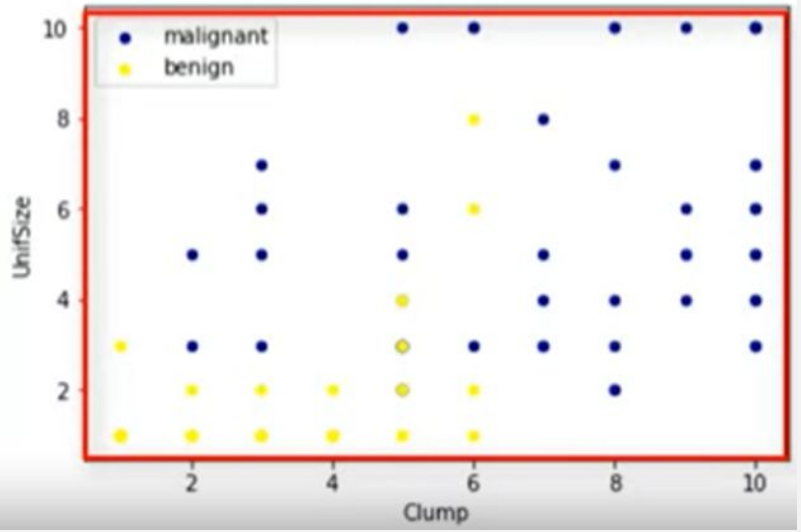
2- Ensuite, un séparateur est estimé pour les données. Les données doivent être transformées de manière à ce qu'un séparateur puisse être dessiné comme un hyperplan.

- Pour la SVM, ce séparateur est appelé « hyperplan ».
- L'hyperplan est une frontière linéaire qui sépare les deux classes => donc sa détermination résout le problème.

Intuition

Il représente un dataset **non linéairement séparable** (qu'est le cas de la majorité des données).

Clump	UnifSize	UnifShape	MargAdh	SingEpiSize	BareNuc	BlandChrom	NormNucl	Mit	Class
5	1	1	1	2	1	3	1	1	benign
5	4	4	5	7	10	3	2	1	benign
3	1	1	1	2	2	3	1	1	malignant
6	8	8	1	3	4	3	7	1	benign
4	1	1	3	2	1	3	1	1	benign
8	10	10	8	7	10		7	1	malignant
1	1	1	1	2	10	3	1	1	benign
2	1	2	H	2	1	3	1	1	benign
2	1	1	1	2	1	1	1	5	benign
4	2	1	1	2	1	2	1	1	benign

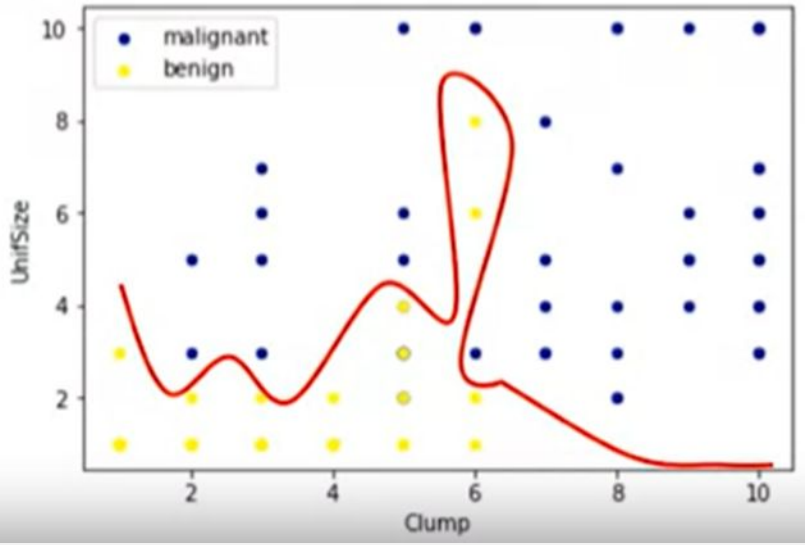


Intuition

Les deux catégories peuvent être séparée par un curve et non pas une droite

Nous pouvons transférer ces données dans un espace de dimension élevé

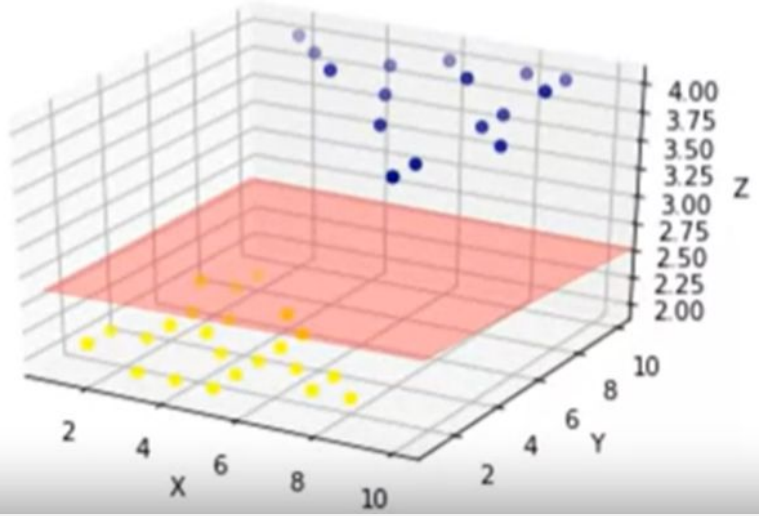
Clump	UnifSize	UnifShape	MargAdh	SingEpiSize	BareNuc	BlandChrom	NormNucl	Mit	Class
5	1	1	1	2	1	3	1	1	benign
5	4	4	5	7	10	3	2	1	benign
3	1	1	1	2	2	3	1	1	malignant
6	8	8	1	3	4	3	7	1	benign
4	1	1	3	2	1	3	1	1	benign
8	10	10	8	7	10		7	1	malignant
1	1	1	1	2	10	3	1	1	benign
2	1	2	H	2	1	3	1	1	benign
2	1	1	1	2	1	1	1	5	benign
4	2	1	1	2	1	2	1	1	benign



Intuition

Mapper les données dans un espace tridimensionnel.

Clump	UnifSize	UnifShape	MargAdh	SingEpiSize	BareNuc	BlandChrom	NormNucl	Mit	Class
5	1	1	1	2	1	3	1	1	benign
5	4	4	5	7	10	3	2	1	benign
3	1	1	1	2	2	3	1	1	malignant
6	8	8	1	3	4	3	7	1	benign
4	1	1	3	2	1	3	1	1	benign
8	10	10	8	7	10		7	1	malignant
1	1	1	1	2	10	3	1	1	benign
2	1	2	H	2	1	3	1	1	benign
2	1	1	1	2	1	1	1	5	benign
4	2	1	1	2	1	2	1	1	benign



- Après la transformation, la limite entre les deux catégories peut être définie par un hyperplan. Comme nous sommes maintenant dans l'espace tridimensionnel, le séparateur est montré comme un plan.
- Ce plan peut être utilisé pour classer des cas nouveaux ou inconnus.
  ⇒SVM génère un hyperplan optimal qui classe de nouveaux exemples

Problématique

Il y a deux questions :

Comment transférer des données de manière à ce qu'un séparateur puisse être dessiné comme un hyperplan ?

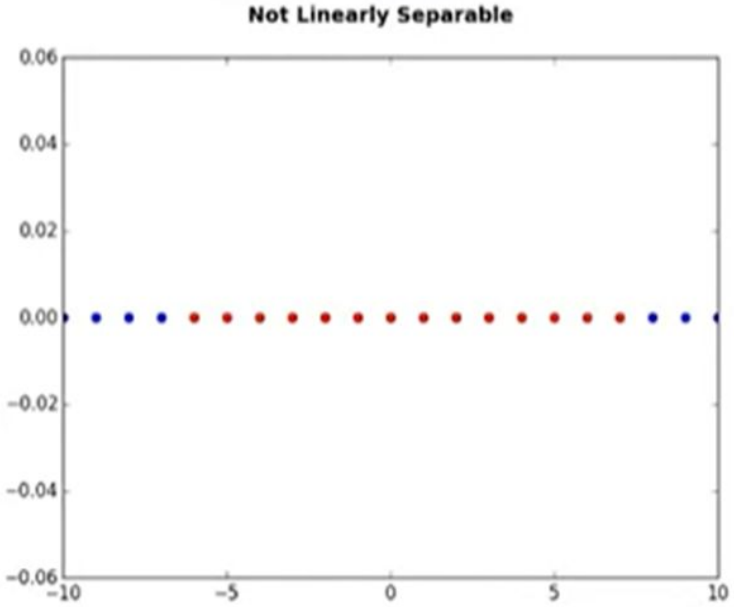
Comment pouvons-nous trouver le meilleur ou optimisé séparateur hyperplan après la transformation ?



Problématique

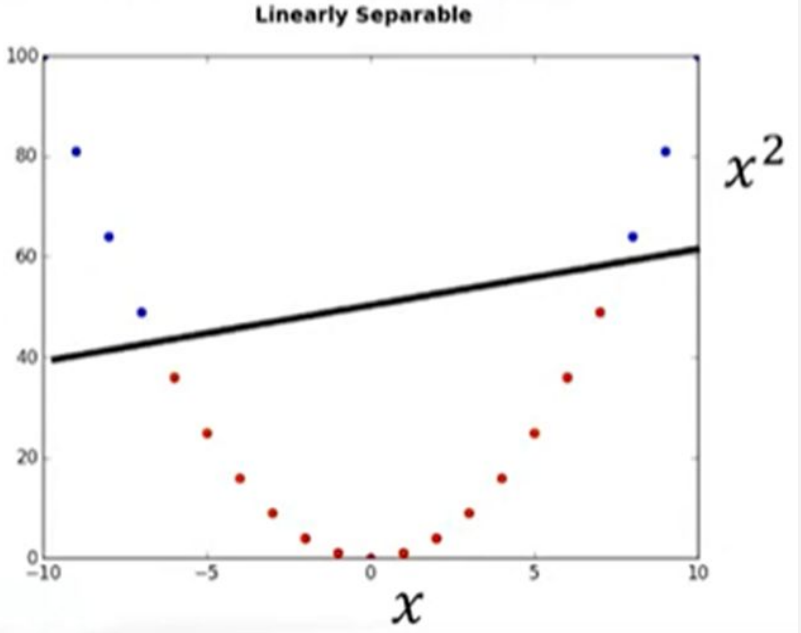
Des données unidimensionnelles. Cela signifie que nous n'avons qu'un seul axe X. Les données sont non linéairement séparables. Qu' est-ce qu'on peut faire ici ?

On peut les transférer dans un espace bidimensionnel. Par exemple, augmenter la dimension des données en mappant x dans un nouvel espace à l'aide d'une fonction avec les sorties x et x au carré.



Kernelling:

- Linear
- Polynomial
- RBF
- Sigmoid



$$\phi(x) = [x, x^2]$$

Activer Windows

Transformation des données

- **Kernelling**: Mapping des données vers un espace dimensional élevé.
- La fonction de mappage s'appelle **Kernel.**
- Le choix de Kernel dépend des données: on fait le test avec les différentes fonctions et on choisit celle avec les meilleurs résultats.
- Les fonctions noyaux les plus connues sont :

Linéaire	$K(x_i, x_j) = < x_i, x_j >$
Polynomial	$K(x_i, x_j) = (< x_i, x_j + 1 >)^d$
RBF (Radial Basic Function)	$K(x_i, x_j) = \exp\left(\frac{-\|x_i - x_j\|^2}{2\beta^2}\right)$
Sigmoïde	$K(x_i, x_j) = \tanh\left(a * < x_i, x_j > -\delta\right)$

Avec « d » est le degré du polynôme,
δ est un paramètre de décalage
a est un paramètre d'échelle pour les données d'entrée.

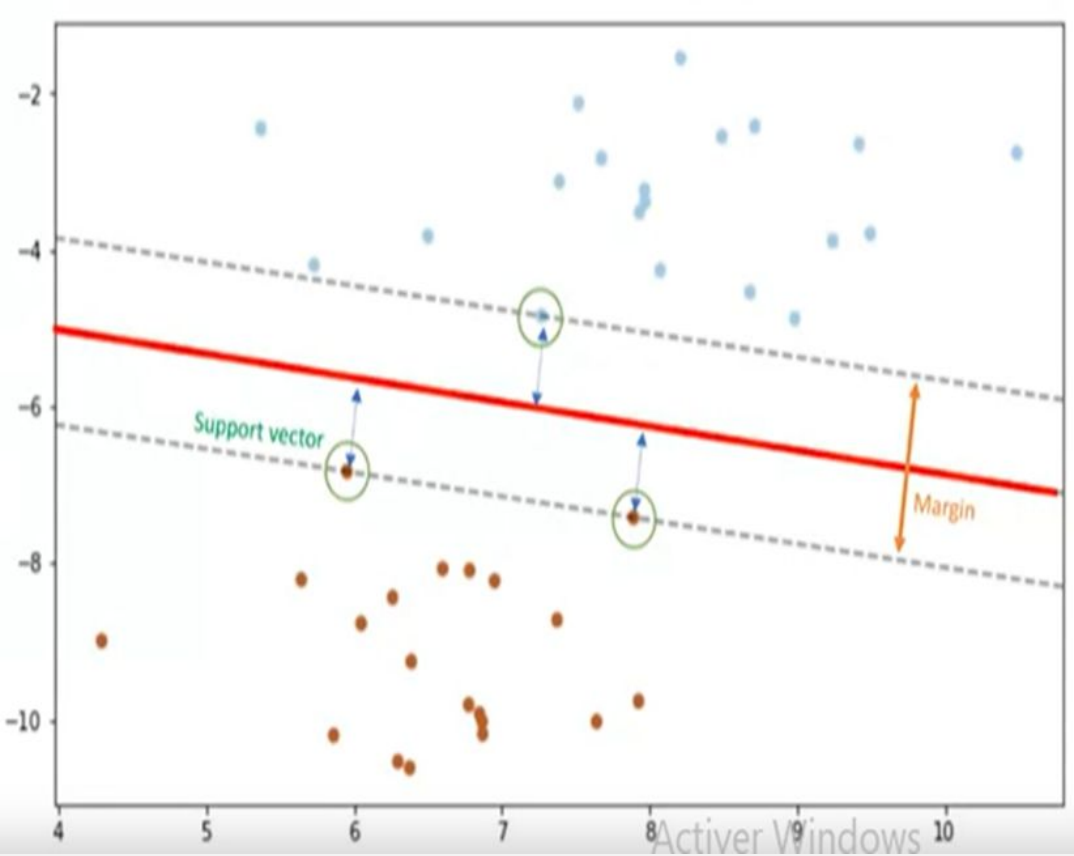
Transformation des données

But: Trouver un hyperplan qui sépare mieux les deux classes.

- Comme on est dans un plan bidimensionnel on peut considérer l'hyperplan comme une droite qui sépare les points rouges de celles bleus.

- *Un choix raisonnable comme meilleur hyperplan est celui qui représente la* ***plus grande séparation*** *ou* ***marge*** ***(margin)*** *entre les deux classes* ⇒ l'objectif de ce modèle est de trouver un hyperplan avec la plus grande marge

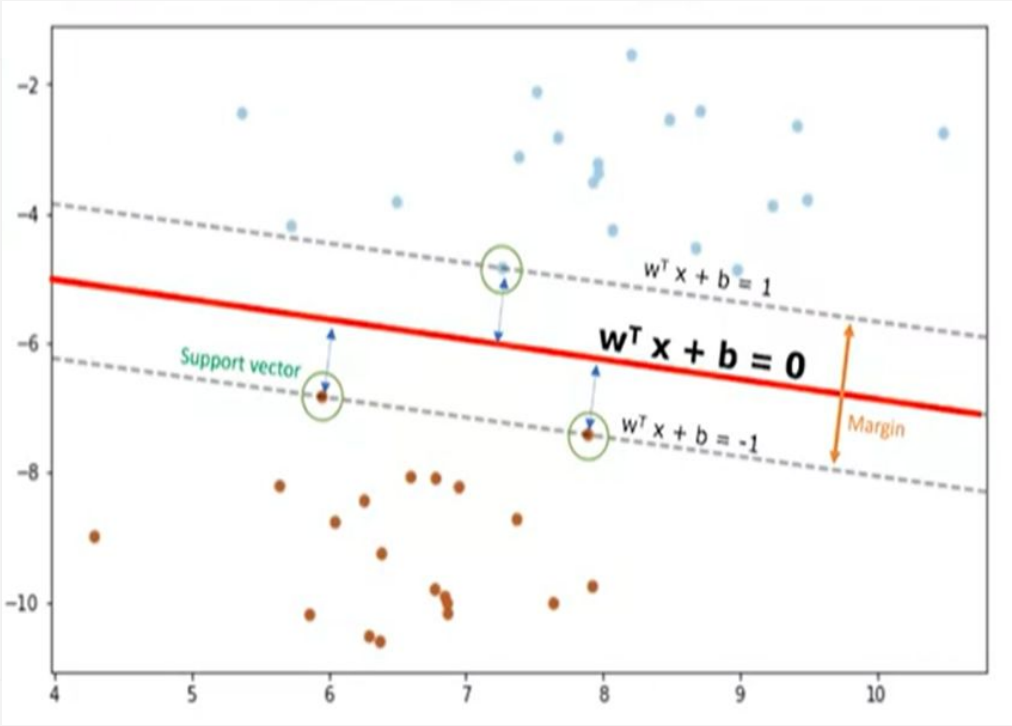
Les support vectors sont les seules qui nous intéresse pour atteindre cet objectif alors, les autres données d'entraînement peuvent être ignorées



Activer Windows

Transformation des données

- L'hyperplan est appris à partir des données d'apprentissage à l'aide d'une procédure d'optimisation maximisant la marge (descente de gradient)
  ⇒ la sortie de l'algorithme est les valeurs w et b de la ligne.
- Les classifications peuvent être effectuées à l'aide de cette ligne estimée. Si l'équation renvoie une valeur supérieure à 0, le point appartient à la première classe, et inversement.



SVM Multi classe

- Les SVM sont bien adaptés aux problèmes à deux classes.
- Pour le cas de plusieurs classes, les SVM multiclasses sont des modèles de l'apprentissage de conception relativement récente.
- Plusieurs extensions des SVM sont proposées au cas multiclasse
- Les deux approches les plus populaires pour le problème multiclasse: **One vs One** et **One vs All**.

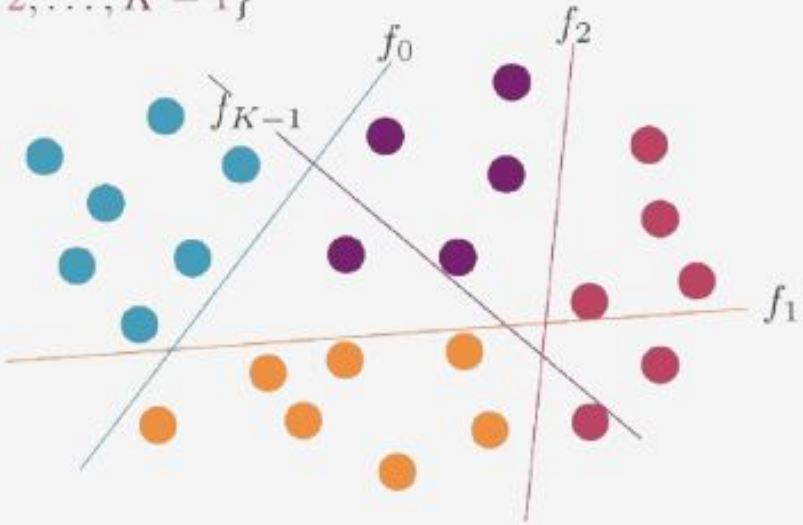


L'étoile noire appartient-elle à la catégorie (carré bleu), la catégorie (triangle vert), ou la catégorie (rond rouge) ?

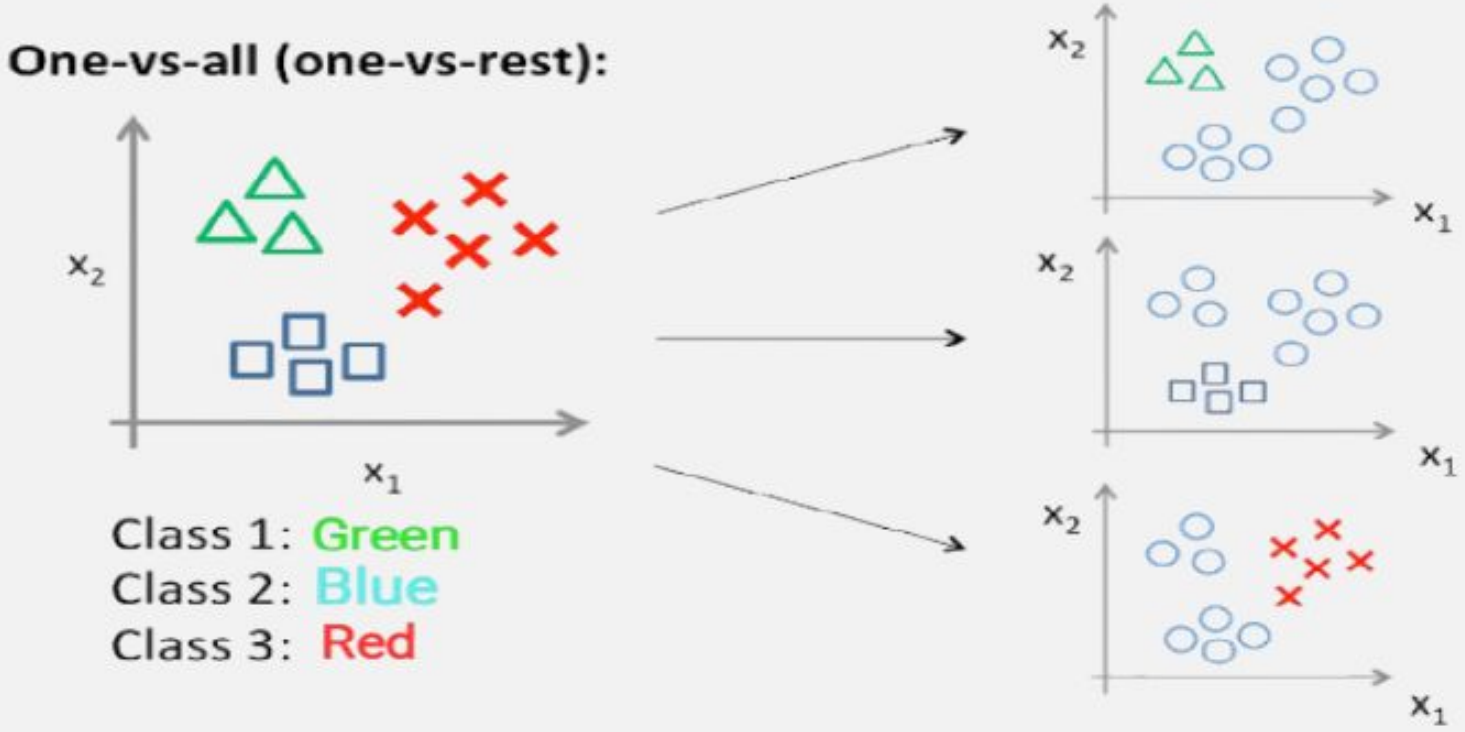
SVM Multi classe: One vs All

- Cette approche consiste à créer un classifieur fk pour chacune des classes, qui sépare les points de cette classe de tous les autres points.

$y \in \{0, 1, 2, \ldots, K-1\}$



SVM Multi classe: One vs All



SVM Multi classe: One vs All

Prédicion

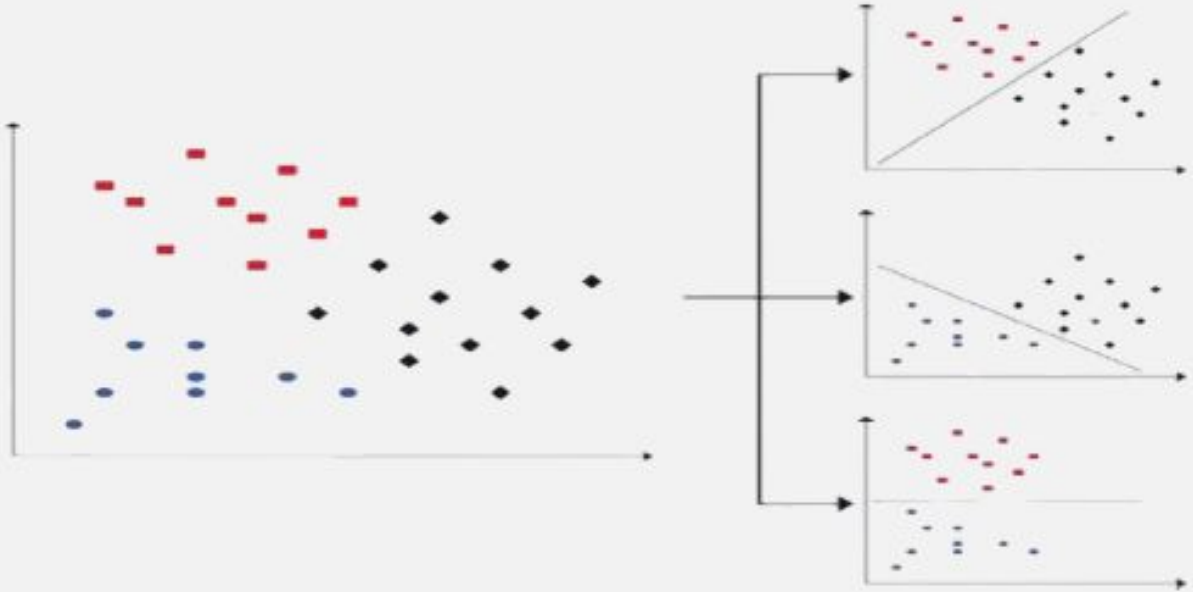
- fk(x) indique la distance entre x et l'hyperplan qui sépare la classe k des autres (fk peut être aussi un score calculant la probabilité d'appartenance) .
- Plus cette valeur est élevée, plus nous sommes convaincus que x appartient à la classe k.

- Nous allons donc simplement prédire **la classe pour laquelle la fonction de décision retourne la valeur la plus élevée :**

$$f(x) = \arg\max_k f_k(x)$$

SVM Multi classe: One vs One

- La méthode One vs One consiste à calculer K(K-1) classifieurs, chacun séparant une classe d'une autre en ignorant les autres classes (et les observations qui leur appartiennent).



SVM Multi classe: One vs One

Prédiction:

- Pour prédire, nous allons utiliser un **vote de la majorité** :

⇒ La classe prédite est celle retournée par le plus grand nombre de classifieurs.

- **Inconvénient:** sa complexité augmente rapidement avec N (nombre des classes) puisqu'elle nécessite $N * (N - 1)$ comparaisons

Avantages de SVM

- Efficace pour les données de haute dimension
- Utilisation des noyaux (kernel trick) : Grâce à la technique du noyau, SVM peut résoudre des problèmes de classification non linéaire en transformant les données dans un espace à plus haute dimension, tout en maintenant une efficacité computationnelle
- Robuste face à l'overfitting (sur-apprentissage)

Limites de SVM

- Moins performant sur des jeux de données bruités et nombreuses
- Sensible au choix du noyau
- **Pas idéal pour la classification multi-classes** : Le SVM est fondamentalement conçu pour des problèmes de classification binaire. Bien qu'il puisse être étendu à des problèmes multi-classes à l'aide de méthodes comme "un contre un" (one-vs-one) ou "un contre tous" (one-vs-all), ces approches ajoutent de la complexité et peuvent ne pas être aussi efficaces que d'autres algorithmes spécifiquement conçus pour traiter plusieurs classes.